



决策树

李 济 宾

中山大学肿瘤防治中心

lijib@sysucc.org.cn





目录

01

决策树概述

03

过拟合与剪枝方法

02

算法原理与划分准则


04

医学案例

1

决策树概述

1.1 决策树概述



决策过程：

1. 先看周末天气，晴朗时判断想不想出门，想就户外，不想就宅家
2. 阴雨则选室内活动，二选一在打游戏和看剧里定。
3. 打游戏的话可以选择从手游和主机游戏中二选一。


如何预测乳腺肿块的良恶性？

No

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	Z	AA	AB	AC	AD	AE	AF	AG	
ID	Diagonal	radius	peradius	texture	texture	texture	spierietexture	perietexture	perietexture	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area	area
1	1 wallpoint	17.99	10.38	122.8	1001	0.1184	0.2776	0.3001	0.1471	0.2419	0.07871	1.090	0.9053	0.589	155.4	0.005939	0.04904	0.05373	0.01587	0.03003	0.00193	25.38	17.33	184.6	2019	0.1022	0.6050	0.7119	0.2094	0.4601	0.1189			
2	2 wallpoint	20.07	17.77	133.9	1320	0.08474	0.07804	0.0809	0.07017	0.1812	0.05067	0.9430	0.7339	3.288	74.08	0.003220	0.01308	0.01380	0.01334	0.01389	0.003332	24.99	23.41	138.8	1999	0.1239	0.1890	0.2410	0.180	0.270	0.08932			
3	3 wallpoint	19.09	31.25	130	1320	0.1296	0.1299	0.1974	0.1279	0.2065	0.03999	0.7456	0.7809	6.980	94.03	0.000310	0.04390	0.00332	0.01008	0.0220	0.04571	23.57	28.53	132.5	1709	0.1444	0.4246	0.4504	0.240	0.3613	0.08756			
4	4 wallpoint	11.42	30.38	77.59	386.1	0.1423	0.2839	0.2434	0.1052	0.2501	0.09744	0.4956	1.156	3.440	27.23	0.00111	0.07458	0.00661	0.00617	0.00962	0.00308	14.91	36.5	98.7	307.7	0.2038	0.8063	0.6889	0.2075	0.6039	0.173			
5	5 wallpoint	20.29	14.34	135.1	1297	0.1003	0.1328	0.1388	0.1043	0.1809	0.08883	0.7572	0.7813	6.438	94.44	0.01149	0.02461	0.00608	0.00893	0.01790	0.0254	26.40	16.07	152.2	1879	0.1374	0.305	0.4075	0.2504	0.3434	0.07038			
6	6 wallpoint	12.49	16.7	82.32	477.1	0.1079	0.1127	0.1080	0.0745	0.2007	0.07633	0.8903	0.7572	2.317	27.19	0.01381	0.03485	0.00367	0.01279	0.02195	0.02195	25.47	23.78	145.4	741.6	0.1791	0.5249	0.9385	0.1741	0.3043	0.1434			
7	7 wallpoint	18.25	18.48	119.8	1040	0.09463	0.1017	0.1127	0.074	0.1794	0.05742	0.4467	0.7732	3.18	50.92	0.00430	0.03020	0.02252	0.01039	0.02395	0.003179	25.88	17.2	185.2	1686	0.1462	0.2549	0.3784	0.1582	0.3063	0.08369			
8	8 wallpoint	13.71	20.83	87.9	477.1	0.1188	0.1045	0.09366	0.09885	0.2194	0.07451	0.5826	1.377	2.888	50.92	0.008906	0.01038	0.02488	0.01448	0.01480	0.005412	17.06	28.14	110.8	897	0.1684	0.3662	0.5378	0.1582	0.3063	0.1154			
9	9 wallpoint	21.31	21.82	87.9	519.8	0.1273	0.1353	0.1489	0.09250	0.2194	0.07451	0.5826	1.377	2.888	50.92	0.008906	0.01038	0.02488	0.01448	0.01480	0.005412	17.06	28.14	110.8	897	0.1684	0.3662	0.5378	0.1582	0.3063	0.1154			
10	10 wallpoint	12.46	24.04	85.97	475.9	0.1186	0.2296	0.2273	0.08543	0.2035	0.08243	0.2976	1.599	2.029	33.94	0.007749	0.05612	0.07217	0.07743	0.04352	0.01789	15.09	40.68	97.65	711.4	0.1851	0.1058	0.1058	0.221	0.4376	0.1072			
11	11 wallpoint	16.02	23.24	102.7	797.8	0.08206	0.06669	0.03299	0.03232	0.1828	0.05697	0.3795	1.87	2.466	40.51	0.004625	0.005069	0.0	0.01291	0.007591	0.01498	15.19	23.38	125.5	1150	0.1181	0.1551	0.1459	0.09975	0.2948	0.08452			
12	12 wallpoint	15.76	17.89	103.6	781	0.0971	0.09554	0.06666	0.06666	0.1842	0.06662	0.5058	0.5058	3.668	54.16	0.00571	0.04601	0.00616	0.01282	0.02008	0.00444	20.42	27.26	136.5	1299	0.1396	0.5609	0.3965	0.181	0.3792	0.1048			
13	13 wallpoint	19.17	24.84	132.4	1123	0.0971	0.2458	0.2065	0.1118	0.2391	0.075	0.9555	0.9849	5.564	11.07	0.0162	0.03129	0.08257	0.02895	0.04048	0.01284	20.9	29.94	161.7	1332	0.1396	0.5609	0.3965	0.181	0.3792	0.1048			
14	14 wallpoint	15.85	25.95	103.7	782.7	0.08401	0.1002	0.09935	0.08924	0.1847	0.05338	0.4033	1.078	2.703	36.58	0.007676	0.05120	0.00501	0.01992	0.02581	0.00302	16.94	27.01	104.5	878.5	0.1131	0.1724	0.2322	0.1193	0.2898	0.06257			
15	15 wallpoint	13.73	22.01	88.9	578.5	0.1131	0.2292	0.2125	0.08925	0.2305	0.07077	0.2121	1.169	2.081	19.21	0.009425	0.03939	0.00510	0.01628	0.01561	0.00803	15.06	32.01	104.5	697.7	0.1051	0.1725	0.2322	0.1193	0.2898	0.06257			
16	16 wallpoint	14.54	27.94	96.73	658.9	0.1131	0.1592	0.1589	0.07964	0.2305	0.07077	0.2121	1.169	2.081	19.21	0.009425	0.03939	0.00510	0.01628	0.01561	0.00803	15.06	32.01	104.5	697.7	0.1051	0.1725	0.2322	0.1193	0.2898	0.06257			
17	17 wallpoint	14.98	30.13	94.74	684.5	0.09807	0.0772	0.07395	0.05259	0.1580	0.05922	0.4727	1.24	2.195	32.05	0.00577	0.0424	0.01986	0.01039	0.01807	0.005466	17.46	30.88	123.4	943.2	0.1678	0.4772	0.7020	0.1712	0.4218	0.1841			
18	18 wallpoint	16.13	30.05	104.1	798.8	0.117	0.2022	0.1732	0.1028	0.2104	0.07350	0.5027	1.073	3.874	54.18	0.007030	0.02001	0.01388	0.01297	0.01685	0.00412	20.30	30.88	130.5	1185	0.1404	0.1871	0.2514	0.1609	0.3029	0.08216			
19	19 wallpoint	19.01	22.19	130	1290	0.09831	0.08128	0.1479	0.09868	0.1582	0.05395	0.7082	1.017	8.805	112.4	0.00494	0.01893	0.03391	0.01521	0.01505	0.00197	27.32	30.48	186.5	1330	0.1789	0.4253	0.4784	0.2073	0.3708	0.1142			
20	20 benin	13.54	14.36	87.49	506.2	0.09779	0.08128	0.09064	0.10781	0.1887	0.07796	0.2699	0.6781	2.058	23.06	0.00492	0.01440	0.02387	0.01315	0.01305	0.00197	27.32	30.48	186.5	1330	0.1789	0.4253	0.4784	0.2073	0.3708	0.1142			
21	21 benin	13.09	15.17	85.33	520	0.1075	0.127	0.04666	0.04781	0.1887	0.07796	0.2699	0.6781	2.058	23.06	0.00492	0.01440	0.02387	0.01315	0.01305	0.00197	27.32	30.48	186.5	1330	0.1789	0.4253	0.4784	0.2073	0.3708	0.1142			
22	22 benin	9.56	12.44	63.24	273.9	0.1024	0.0236	0.0236	0.02071	0.1815	0.05338	0.7477	1.393	14.3	15.2	0.006907	0.01436	0.01980	0.01423	0.02027	0.00429	15.23	26.9	96.9	630.5	0.1313	0.3770	0.1773	0.239	0.1288	0.297	0.07529		
23	23 wallpoint	15.34	14.26	102.7	704.4	0.1131	0.2132	0.2077	0.09759	0.2811	0.07032	0.508	1.098	3.708	44.91	0.006778	0.03329	0.00445	0.02323	0.02027	0.00429	15.23	26.9	96.9	630.5	0.1313	0.3770	0.1773	0.239	0.1288	0.297	0.07529		
24	24 wallpoint	21.16	22.04	137.2	1480.8	0.09428	0.1022	0.1097	0.08832	0.2809	0.05278	0.6917	1.127	3.703	44.91	0.006778	0.03329	0.00445	0.02323	0.02027	0.00429	15.23	26.9	96.9	630.5	0.1313	0.3770	0.1773	0.239	0.1288	0.297	0.07529		
25	25 wallpoint	17.14	24.4	119	912.7	0.1186	0.2275	0.2229	0.1401	0.204	0.07413	1.046	0.974	2.726	111.4	0.008029	0.01892	0.03352	0.01303	0.02008	0.007444	22.25	21.4	152.4	1461	0.1545	0.2949	0.3853	0.285	0.4066	0.1059			
26	26 wallpoint	14.59	21.83	97.41	544.8	0.1054	0.1868	0.1425	0.08783	0.2252	0.06904	0.2548	0.9832	2.11	21.05	0.004452	0.03055	0.02881	0.01352	0.01454	0.003711	17.62	33.21	122.4	896.9	0.1525	0.2643	0.3539	0.2701	0.4264	0.1275			
27	27 wallpoint	18.01	20.25	123.1	1094	0.0944	0.1066	0.149	0.07731	0.1697	0.05899	0.8529	1.849	5.832	92.54	0.01075	0.02722	0.05061	0.01911	0.02295	0.004217	17.21	27.26	139.5	1405	0.1358	0.2117	0.3446	0.140	0.2341	0.07421			
28	28 wallpoint	15.3	25.27	102.4	732.4	0.1082	0.1697	0.1483	0.08751	0.1504	0.0654	0.439	1.012	3.498	43.5	0.005233	0.03057	0.03676	0.01683	0.01768	0.002967	20.27	26.71	148.5	1269	0.1641	0.41	0.6355	0.2024	0.4027	0.09876			
29	29 wallpoint	17.87	15.05	115	958.1	0.09847	0.1157	0.09676	0.07953	0.1739	0.06149	0.6003	0.8225	4.665	61.1	0.005827	0.03033	0.03407	0.01354	0.01925	0.003742	20.01	19.82	134.9	1227	0.1552	0.2812	0.2469	0.1456	0.2756	0.07919			
30	30 wallpoint	18.63	25.11	124.8	1088	0.1064	0.1987	0.2219	0.1244	0.2183	0.06197	0.8307	1.466	5.774	105	0.006248	0.03374	0.05196	0.01158	0.02007	0.00456	23.15	19.01	140.5	1670	0.1491	0.4277	0.4133	0.1848	0.4444	0.09782			
31	31 wallpoint	11.84	37.7	77.93	440.6	0.1109	0.1516	0.1218	0.05182	0.2301	0.07795	0.4825	1.03	3.475	41	0.015581	0.03414	0.04206	0.01944	0.02273	0.005667	16.82	28.12	118.4	888.7	0.1637	0.5775	0.6566	0.1566	0.4761	0.1402			
32	32 wallpoint	17.02	25.88	112.8	899.3	0.1197	0.1496	0.2417	0.1203	0.2248	0.06382	0.6005	1.398	3.999	67.78	0.006266	0.03032	0.05042	0.01112	0.02102	0.003554	20.88	32.09	136.1	1344	0.1634	0.3559	0.5588	0.1847	0.353	0.08482			
33	33 wallpoint	15.27	26.47	127.3	1182	0.09401	0.1715	0.1657	0.07593	0.1832	0.06261	0.5558	0.6042	3.528	68.17	0.01015	0.03818	0.03457	0.009443	0.01540	0.003596	24.15	30.9	161.4	1813	0.1509	0.659	0.6093	0.1785	0.3072	0.1123			
34	34 wallpoint	10.74	17.88	107	807.2	0.104	0.1553	0.1354	0.07732	0.1948	0.05215	0.334	0.6857	2.133	35.03	0.004185	0.02866	0.02664	0.009607	0.01703	0.003817	20.21	27.26	132.7	1261	0.1464	0.5804	0.5274	0.1864	0.427	0.1233			
35	35 wallpoint	16.74	21.99	110.1	869.5	0.0961	0.133																											


1.1 决策树概述

- 一种基于树形结构的机器学习方法；
- 用于**分类**（分类树）和**回归**（回归树）任务；
- 模型由节点（特征）、分支（特征取值）、叶子（结果）构成；
- 基本思想：对自变量进行**二元/多元分离**，从而构造一棵可用于预测新观测值所属类别的树；
- 像**医生问诊**一样，不断提出分裂性问题，最后得到**诊断结论**



1.1 决策树概述

例. 威斯康星乳腺癌数据集




1.2 决策树在医学中的应用

● 辅助诊断

包括临床体征、影像学检查和病理学检查等步骤，辅助医生在早期阶段识别高风险患者。

决策树模型基于临床标志物和术前循环血细胞预测卵巢肿瘤恶性程度



1.2 决策树在医学中的应用

● 辅助诊断

分类与回归树算法 (CART) 预测心脏病




Fig. 2. Graphical representation of the CART approach.

1.2 决策树在医学中的应用

● 预测预后

分析患者的年龄、肿瘤大小、淋巴结状态等特征，有效预测了疾病的复发风险。

预测接受根治性膀胱切除术治疗的膀胱癌患者癌症特异性生存率





Figure 1. Conditional inference tree with derivation cohort. Following this figure, we can classify and stratify the risk of death due to bladder cancer of our patients. The final image is the survival curve using the conditional inference tree for each subgroup of patients and the number of patients included in each subgroup.

1.2 决策树在医学中的应用

● 预测预后

分析患者的年龄、肿瘤大小、淋巴结状态等特征，有效预测了疾病的复发风险。

生存预后因素在成人复发性胶质母细胞瘤患者中的应用



1.3 决策树优缺点

优点

- 推理过程容易理解，计算简单，可解释性强。
- 比较适合处理有缺失属性的样本。
- 可自动忽略目标变量没有贡献的属性变量，也为判断属性变量的重要性减少变量的数目提供参考。

缺点

- 容易造成过拟合，需要采用剪枝操作。
- 忽略了数据之间的相关性。
- 对于各类别样本数量不一致的数据，信息增益会偏向于那些更多数值的特征。

1.4 决策树概述小结

- **核心机制** → 不断提出最佳问题（特征分裂）
- **最终结果** → 叶子节点给出分类（M/B）

为什么先分“肿瘤半径”，而不是“肿瘤质地”？？？




2

算法原理与划分准则



2.1 如何选定最佳划分点



- 决策树的本质：把“杂乱”的样本不断划分，直到“纯净”。
- 医学类比：医生问诊时，通过逐步提问，把人群缩小到高风险或低风险。
- 数据场景：569个乳腺癌样本（M/B混合），如何一步步区分？



2.1 如何选定最佳划分点

什么特征是进行分类的最佳特征？

- 不是所有特征都一样重要。
- 我们希望选择的特征能最大程度地区分良性和恶性。
- 举例：
 - “病人ID” → 毫无意义（不能区分良恶性）
 - “肿瘤半径是否大于阈值” → 区分度明显



2.2 决策树常见算法

- 建立决策树的关键，即在当前状态下选择哪个属性作为分类依据。
- 根据不同的目标函数，建立决策树主要有以下三种算法：**ID3** (Iterative Dichotomiser)、**C4.5**、**CART** (Classification And Regression Tree)

算法	支持模型	树结构	特征选择指标	连续值处理	缺失值处理	剪枝
ID3	分类	多叉树	信息增益	不支持	不支持	不支持
C4.5	分类	多叉树	信息增益率	支持	支持	支持
CART	分类 回归	二叉树	基尼指数 均方差	支持	支持	支持

2.3 ID3算法

- 最早是由 J.Ross Quinlan 于1975年提出的一种决策树构建算法，算法的核心是“**信息熵**”，期望信息越小，信息熵越大，样本纯度越低。
- 以信息论为基础，以**信息增益**为衡量标准，从而实现对数据的归纳分类。
- 计算每个属性的信息增益，并选取具有最高增益的属性作为给定的测试属性。

- 其大致步骤为：
 1. 初始化特征集合和数据集合；
 2. 计算候选特征的信息增益；
 3. 选择最大增益特征进行分裂；
 4. 重复2，3两步，若子集值包含单一特征，则为分支叶子节点。

2.3 ID3算法

- 信息熵 (Entropy): 衡量样本集合的不确定性


$$H(D) = - \sum_{k=1}^K \frac{|C_k|}{|D|} \log_2 \frac{|C_k|}{|D|}$$

K 是类别, D 是数据集, C_K 是类别 K 下的数据集
熵随概率变化的曲线 (p vs. $H(p)$, 峰值在 0.5)

- 在威斯康星州的乳腺癌数据集中:

已知 569 例样本中有 357 例良性, 212 例恶性

$$H = - \left(\frac{357}{569} \log_2 \frac{357}{569} + \frac{212}{569} \log_2 \frac{212}{569} \right) \approx 0.956$$



2.3 ID3算法


- 信息熵(Entropy): 衡量样本集合的不确定性

$$H(D) = - \sum_{k=1}^K \frac{|C_k|}{|D|} \log_2 \frac{|C_k|}{|D|}$$

- 条件熵 $H(D | A)$: 在已知特征 A 的情况下, 目标变量 D 的剩余不确定性。

$$H(D|A) = \sum_{i=1}^n \frac{|D_i|}{|D|} H(D_i)$$

A 是特征, i 是特征取值



2.3 ID3算法

在威斯康星州的乳腺癌数据集中：

569 例，按特征 “mean radius > 15” 划分

信息熵：

组1: radius $\leq 15 \rightarrow$ 476 例（良性 344，恶性 132）

- $p_B = 344/476 \approx 0.723$
- $p_M = 132/476 \approx 0.277$

$$H_1 = -0.723 \log_2(0.723) - 0.277 \log_2(0.277) \approx 0.849$$

组2: radius > 15 $\rightarrow$ 93 例（良性 13，恶性 80）

- $p_B = 13/93 \approx 0.140$
- $p_M = 80/93 \approx 0.860$

$$H_2 = -0.140 \log_2(0.140) - 0.860 \log_2(0.860) \approx 0.574$$

加权平均（条件熵）

$$H(D|A) = \frac{476}{569} H_1 + \frac{93}{569} H_2$$

$$H(D|A) \approx 0.837 \times 0.849 + 0.163 \times 0.574$$

$$H(D|A) \approx 0.801$$

2.3 ID3算法

信息增益 (gain): 分裂后熵下降多少

$$g(D, A) = H(D) - H(D|A) \quad \text{其中 } H(D) \text{ 是信息熵, } H(D|A) \text{ 是条件熵}$$

还是以特征 “mean radius > 15” 为例, 此时

$$g(D, A) = H(D) - H(D|A) \approx 0.956 - 0.801 = 0.155$$

结论: 用 “mean radius > 15” 这个特征去划分, 可以减少约 0.155 bit 的不确定性

2.3 ID3算法

优缺点

优点

- 思想直观，易理解，计算清晰
- 最早的系统化决策树算法
- 在小型分类问题中表现尚可

不足

- 偏向取值多的特征（如身份证号）
- 无法处理连续变量
- 无剪枝机制，容易过拟合
- 对缺失值不鲁棒

2.4 C4.5算法

C4.5 算法是 Ross 对 ID3算法的改进。

- 用信息增益率来选择属性。ID3选择属性用的是子树的**信息增益**，而C4.5用的是**信息增益率**。
- 在决策树构造过程中进行**剪枝**。
- 对**非离散数据**也能处理。
- 能够对**不完整数据**进行处理。
- C4.5会优先考虑“**增益率最高**”的特征



2.4 C4.5算法

信息增益

$$g(D, A) = H(D) - H(D|A)$$

分裂信息 (SplitInfo)

$$SplitInfo(A) = - \sum_{v \in Values(A)} \frac{|D_v|}{|D|} \log_2 \frac{|D_v|}{|D|}$$

信息增益率 (Gain Ratio)

$$GainRatio(D, A) = \frac{g(D, A)}{SplitInfo(A)}$$

2.4 C4.5算法

回到威斯康星州数据

假设用特征 “mean radius > 15” 划分

1. 前文已知：

信息增益：Gain $\approx$ 0.155

2. 分裂信息（2组划分：476 vs 93）

$$SplitInfo \approx - \left(\frac{476}{569} \log_2 \frac{476}{569} + \frac{93}{569} \log_2 \frac{93}{569} \right) \approx 0.619$$

3. 信息增益率

$$GainRatio \approx \frac{0.155}{0.619} \approx 0.25$$

信息熵：

组1：radius $\leq$ 15 $\rightarrow$ 476 例（良性 344，恶性 132）

组2：radius > 15 $\rightarrow$ 93 例（良性 13，恶性 80）

2.4 C4.5算法

连续特征处理

1. 先对样本按特征值排序
2. 在相邻样本之间尝试分裂点（如 $\text{radius}=14.8, 15.3\dots$ ）
3. 计算每个候选分裂点的信息增益率
4. 选最优阈值

2.4 C4.5算法

缺失值处理

如果某个特征在部分样本中缺失：

- 用该特征已知部分的分布来估计
- 或者在划分时给不同分支分配权重

优点：数据**利用率高**，不需要删除缺失样本

2.4 C4.5算法

优缺点

优点

- 思想直观，易理解，计算清晰
- 最早的系统化决策树算法
- 在小型分类问题中表现尚可

不足


- 偏向取值多的特征（如身份证号）
- 无法处理连续变量
- 无剪枝机制，容易过拟合
- 对缺失值适应性较差



2.4 CART算法

- 既可以用于创建分类树，也可以用于创建回归树，两者在构建的过程中稍有差异。
- 用**基尼指数**来选择属性（分类），用**均方差**来选择属性（回归）
- 基尼指数越接近 0，数据集越纯净。
- 如果目标变量是**离散**的，称为分类树
- 如果目标变量是**连续**的，称为回归树

2.5 CART算法



2.5 CART算法——分类

连续特征处理思路

1. 排序该特征的所有样本值。
2. 生成候选切分点：取相邻两个值的中点作为阈值。
3. 二分划分：

每个候选点都能把数据分成两部分：

左子集：特征 $\leq$ 阈值


右子集：特征 $>$ 阈值

4. 计算基尼指数 (Gini)


5. 选择最优切分点：能使基尼指数下降最多的那个阈值。

2.5 CART算法——分类

第1次划分




第2次划分



.....

第 $m-1$ 次划分



例如取到的基尼指数最小的点为 a_t ，则小于 a_t 的值为类别1，大于 a_t 的值为类别2，这样就做到了连续特征的离散化，接着采用基尼指数的大小来度量特征的各个划分点

2.5 CART算法——分类

离散特征处理思路

- CART 必须保持二叉树结构
- 把所有类别的可能组合尝试一遍，然后挑出最优划分。

举例 病理类型 $\{A, B, C\} \rightarrow$ 所有可能的二分方式

1. $\{A\}$ vs $\{B, C\}$

2. $\{B\}$ vs $\{A, C\}$

3. $\{C\}$ vs $\{A, B\}$

2.5 CART算法——分类

第1次划分



第2次划分



.....

第 m 次划分



例如第1次取 $\{a_1\}$ 为类别1, 那么剩下的特征 $\{a_2, a_3, \dots, a_{m-1}, a_m\}$ 为类别2, 由此遍历, 第 m 次取 $\{a_m\}$ 为类别1, 那么剩下的特征 $\{a_1, a_2, a_3, \dots, a_{m-1}\}$ 为类别2。

2.5 CART算法——分类

基尼指数 (Gini index) : 度量一个集合的不纯度

$Gini(D, A)$ 表示经过 $A = a$ 分割后集合 D 的不确定性。

$$Gini(D, A) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2)$$

D : 样本集合

K : 类别数

P_k : 第 k 类样本的概率

$$Gini(D) = 1 - \sum_{k=1}^K p_k^2$$

- 如果一个集合**完全纯净**（全是良性或全是恶性），**基尼指数 = 0**
- 越接近 **0**，数据集越纯净。
- 选取**使分裂后基尼指数最小**的属性和阈值



2.5 CART算法——分类

基尼指数 (Gini index) : 度量一个集合的不纯度

1. 还是用乳腺癌数据: 总样本数 (569) 良性 (357) 恶性 (212)

$$\text{总基尼系数: } Gini(D) = 1 - \left[\left(\frac{357}{569} \right)^2 + \left(\frac{212}{569} \right)^2 \right] = 0.468$$

2. 假设划分条件: mean radius > 15

➤ 左子集 (≤ 15) : 476个样本 (其中 344良性, 132恶性)

$$Gini(D_L) = 1 - \left[\left(\frac{344}{476} \right)^2 + \left(\frac{132}{476} \right)^2 \right] = 0.4008$$

➤ 右子集 (> 15) : 93个样本 (其中 13良性, 80恶性)

$$Gini(D_R) = 1 - \left[\left(\frac{13}{93} \right)^2 + \left(\frac{80}{93} \right)^2 \right] = 0.2409$$



2.5 CART算法——分类

基尼指数 (Gini index) : 度量一个集合的不纯度

3. 加权平均基尼指数

$$Gini(D, A) = \frac{476}{569} \times Gini(D_L) + \frac{93}{569} \times Gini(D_R) = 0.3745$$

4. 基尼指数下降量

$$\Delta Gini = 0.468 - 0.3745 = 0.0935$$

2.5 CART算法——分类

分类与回归树算法 (CART) 预测心脏病




Fig. 2. Graphical representation of the CART approach.



2.5 CART算法——回归

分类树：最小化分类的不纯度（基尼指数）

回归树：最小化预测误差（通常用均方差 MSE）



分类树 → 每个叶子节点是“类别标签”

回归树 → 每个叶子节点是“数值预测”（通常是该叶子样本的均值）

2.5 CART算法——回归

对于连续值的处理，以均方误差（MSE）的大小作为划分标准。对于任意划分特征 A ，对应的任意划分点 s 两边划分成的数据集 D_1 和 D_2 ，分别计算两部分的均方误差，选择使得两部分加权均方误差之和最小的划分点作为最优切分点。表达式为：

$$\min_{a,s} [\min_{c_1} \sum_{x_i \in D_1} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in D_2} (y_i - c_2)^2]$$

c_1 为 D_1 数据集的样本输出均值

c_2 为 D_2 数据集的样本输出均值

x_i 表示第 i 个样本

y_i 表示第 i 个样本的目标变量值

a 表示左子节点样本数占总样本数的比例

s 表示右子节点样本数占总样本数的比例

2.5 CART算法——回归

类比乳腺癌数据

Sample	mean radius	生存时间
1	12.0	80
2	14.5	75
3	13.0	60
4	16.0	36
5	17.5	30
6	18.0	20

候选分割点：假设选择12.5、13.75、15.25、16.75、17.75

以分割点15.25为例：

左子集：

生存时间 = [80, 75, 60]

平均值 = 71.67

方差 ≈ 72.2

右子集：

生存时间 = [40, 35, 20]

平均值 = 28.67

方差 ≈ 43.6

加权MSE=57.9

计算其他分裂点

分裂点12.5：加权方差 = 314.7

分裂点13.75：加权方差 = 236.8


分裂点16.75：加权方差 = 392.2

分裂点17.75：加权方差 = 376.9

在乳腺癌小样本数据中，若以 mean radius = 15.25 作为切分点，能够较好地
将生存时间较长的患者（>60月）与生存时间较短的患者（<40月）区分开。


2.5 CART算法——回归

AIS Grade: 美国脊髓损伤协会损伤分级
NLI: 神经损伤平面;
Age: 年龄



Abbreviations :

SCIM : Spinal Cord Injury Motor score
NLI : Neurological Level of injury
AIS Grade : American Spinal Injury Association Impairment Scale
LC : Low Cervical
TH : Thoracic
TL : Thoracolumbar



2.5 CART算法

CART 在分类中的优势与局限

优势

- 基尼指数作为分裂标准，计算简单高效
- 能输出类别概率（如“恶性 80%，良性 20%”），而不是单一标签
- 在乳腺癌分类任务中，能给出清晰的决策路径（如 “mean radius > 15 → 恶性”）

局限

- 容易过拟合（尤其在特征多时）
- 分类边界是“阶梯状”，对连续空间划分不够平滑
- 对样本分布敏感，轻微变化可能导致树结构大幅调整

2.5 CART算法

CART 在回归中的优势与局限

优势

- 能处理非线性和复杂交互关系
- 预测值 = 节点内样本均值（或中位数），直观易解释
- 在乳腺癌预后预测中，可给出生存时间的区间划分

局限

- 对连续变量预测不够平滑，结果是“阶梯式”而非连续曲线
- 对极端值敏感（均值可能被异常值干扰）
- 当样本量很小时，预测值可能波动较大

2.6 算法原理小结

算法	分裂准则	特点	局限性
ID3	信息增益	简单直观	偏向取值多的特征， 易过拟合
C4.5	信息增益率	修正 ID3 偏好， 支持连续特征	计算复杂度较高
CART	分类→基尼指数 回归→最小化MSE	二叉树结构统一， 应用广泛	容易生成过深的树， 需剪枝

三者都解决了“如何选最优分裂点”的问题，但都存在过拟合风险。

3

过拟合与剪枝方法

3.1 基本概念

过拟合

什么是过拟合现象：

- 树无限生长，训练集准确率接近 100%。
- 测试集效果反而变差。

原因：

- 过度拟合训练集中的噪音和偶然规律。

例子（乳腺癌数据）：

大树可能“死记硬背”每一个特征细节。

结果：对 569 个训练样本表现很好，但对新患者预测不佳。

3.1 基本概念

剪枝

核心思想

➤ 与其让树无限长，不如“砍掉”一些不必要的分支，让模型更简洁、更具泛化能力。

类比：

决策树就像一个长满枝叶的大树。

剪枝 = 修枝 → 去掉多余的枝叶，让树保持健康生长。

3.2 剪枝

剪枝的分类

- **预剪枝** (Pre-pruning)：在树生长过程中就停止扩展
- **后剪枝** (Post-pruning)：先长成完整大树，再回过头来修剪
- **悲观剪枝** (Pessimistic Pruning)：C4.5 提出的特殊后剪枝，不依赖验证集

对比

- 预剪枝：提前刹车
- 后剪枝：先走到底，再回退
- 悲观剪枝：不用验证集，靠训练集修正

3.2 剪枝

预剪枝

机制

- 在节点分裂前，先评估是否值得分裂。
- 常用C4.5

常见停止条件

- 信息增益（率）（或基尼指数）< 设定阈值
- 节点样本数 < 最小样本阈值
- 树深度 $\geq$ 最大深度
- 分裂后准确率提升不显著

例子

- 如果在乳腺癌数据中，某个节点样本少，继续分裂意义不大，可以直接停止

3.2 剪枝

预剪枝

预剪枝不仅可以降低过拟合的风险而且还可以减少训练时间，但另一方面它是基于“贪心”策略，会带来欠拟合风险。

剪枝策略

在节点划分前来确定是否继续增长，及早停止增长

- 节点内数据样本低于某一阈值
- 所有节点特征都已分裂
- 节点划分前准确率比划分后准确率高

3.2 剪枝

预剪枝

优点

- 简单快速，计算成本低
- 树结构更简洁，易解释
- 能有效避免“过度拟合小样本”

缺点

- 可能“过早截断”，导致有价值的分裂被忽略
- 容易出现欠拟合

剪枝

3.2 剪枝

预剪枝

为了防止过拟合和生成过多小叶子，我们对树生长设置了以下限制条件：

1. 最小划分样本数

内部节点至少需要 20 个样本才能继续划分

作用：防止叶子样本过少，保证划分可靠性

2. 叶子最小样本数

每个叶子节点至少包含一定数量的样本（最小划分样本数/3）

作用：保证每个叶子的样本足够支撑预测

3. 最大深度


树的深度最多为 5 层

作用：控制树的整体复杂度，使结构清晰易解释

4. 复杂度参数

节点划分必须能降低训练误差至少 1%

作用：只允许有效划分，避免生成对训练误差提升不显著的分支



3.2 剪枝

后剪枝

- 常用于CART
- 在已经生成的决策树上进行剪枝，从而得到简化版的剪枝决策树
- 后剪枝决策树通常比预剪枝决策树保留了更多的分支
- 一般情况下，后剪枝的欠拟合风险更小，泛化性能往往优于预剪枝决策树

机制：

- 先生成一棵“完全树”，让模型充分学习
- 再逐步检查各个子树 → 如果合并成叶子后误差没变甚至更小，就进行剪枝
- 通常需要验证集或交叉验证来评估误差变化

3.2 剪枝

后剪枝

方法流程

- 从树底部开始，逐个检查子树
- 计算该子树的分类错误率（或预测误差）
- 计算合并为一个叶子时的错误率
- 比较两者 → 如果合并后效果不差，剪掉子树

优点

- 泛化能力更强，避免过早截断

缺点


- 计算成本高
- 需要验证集/交叉验证

3.2 剪枝

后剪枝

以最小化交叉验证误差为依据

- 检查每个子树 → 评估剪掉某些叶子后，交叉验证误差是否更低
- 剪掉叶子不增加误差或降低误差 → 剪掉
- 最终选出交叉验证误差最小的子树



3.2 剪枝

悲观剪枝

C4.5中一种典型的后剪枝方法，用**递归**的方式从低往上针对每一个非叶子节点，评估用一个最佳叶子节点去代替这棵子树是否有益。如果剪枝后与剪枝前相比其错误率是保持或者下降，则这棵子树就可以被替换掉

核心思想

- 训练集误差通常过于乐观
- 给误差加一个“修正值”，假设实际错误会更高 → 悲观一些

3.2 剪枝

悲观剪枝

方法流程

- 计算子树错误数: e
- 给 e 加上修正 (如 +0.5 或置信区间上限) 得到修正后错误数 E (其中 L 为叶子数)

$$E = \sum_i e_i + 0.5 * L$$

- 比较“保留子树 vs 合并叶子”的修正后错误数
- 若合并更优 → 剪枝

优点

- 不依赖验证集, 计算简单

缺点

- 欠拟合风险高

威斯康星乳腺癌数据某子树:

- 叶子1: 10 样本, 2个错误 → 错误数 $e=2$
- 叶子2: 10 样本, 3个错误 → 错误数 $e=3$
- $E = 2+3+0.5*2 = 6$



若合并为一个叶子 (多数类 = 良性):

- 若重新预测的错误 $e = 5$
- 修正后: $E = 5+0.5*1=5.5$

则倾向于使用悲观剪枝, 降低复杂程度

- 若重新预测的错误 $e = 8$
- 修正后: $E = 8+0.5*1=8.5$

则倾向于不使用悲观剪枝



4

医学案例



4.1 决策树的R语言实现

例1. 威斯康星乳腺癌数据集



Breast Cancer Wisconsin (Diagnostic)

Donated on 10/31/1995

Diagnostic Wisconsin Breast Cancer Database.

Dataset Characteristics	Subject Area	Associated Tasks
Multivariate	Health and Medicine	Classification

Feature Type	# Instances	# Features
Real	569	30

Dataset Information

Additional Information

Features are computed from a digitized image of a fine needle aspirate (FNA) of a breast mass. They describe characteristics of the cell nuclei present in the image. A few of the images can be found at [http://www.cs.wisc.edu/~street/images/...](http://www.cs.wisc.edu/~street/images/)

SHOW MORE ▾

Has Missing Values?
No

[DOWNLOAD \(50.1 KB\)](#)
[IMPORT IN PYTHON](#)
[CITE](#)
” 37 citations
👁 518309 views

Keywords

health cancer

Creators

- William Wolberg
- Olvi Mangasarian
- Nick Street
- W. Street



4.1 决策树的R语言实现

例1. 威斯康星乳腺癌数据集

数据来源

- 该数据集由威斯康星大学医院的临床实验室采集。
- **研究对象**：乳腺肿块患者，金标准确诊良性：357 ； 恶性：212 。
- **检测方法**：通过细针抽吸活检（Fine Needle Aspiration, FNA）获取细胞学特征。

研究目的

- 根据乳腺细胞的形态学特征，建立机器学习模型，预测患者肿块是良性（Benign）还是恶性（Malignant）。
- 为临床医生提供一种快速、低成本的辅助诊断工具。



4.1 决策树的R语言实现

例1. 威斯康星乳腺癌数据集

数据特征

- 共 569 个样本（训练+验证）。
- 30 个数值型特征（如：半径、质地、周长、面积、平滑度、紧致度、凹陷度等）。
- 标签变量：Diagnosis（M = 恶性，B = 良性）。

分析任务

- 输入：乳腺细胞的显微镜图像转化的数值特征。
- 输出：二分类预测（是否恶性）。

4.1 决策树的R语言实现



算法基础

	rpart——经典决策树	ctree——条件决策树
原理	属于贪心算法：在每一步中均选择使“纯度提升”最大的分裂点。	先检验变量和目标变量是否显著相关，再选择显著性最强的变量做分裂。不是简单追求纯度，而是追求统计显著性。
划分标准	默认使用 基尼指数 选择最佳划分变量，但是也允许在样本分布不均衡时使用 信息增益	使用 条件独立检验 （permutation test）评估变量与目标的统计显著性
是否存在选择偏倚	有偏倚（倾向于选择取值较多的变量）	无偏倚（通过统计检验控制变量选择偏倚）
剪枝机制	通过复杂度参数 cp 控制过拟合	不需要传统剪枝，通过 p 值阈值（如 $\alpha = 0.05$ ）自动停止划分
划分停止准则	基于最小样本数、cp 值、最大深度等	基于条件检验的显著性（ p 值 $> \alpha$ ）自动停止
计算速度	较快，适合大样本	稍慢
结果解释性	易于解释，但可能存在过拟合	解释性强，统计意义明确
适用场景	快速建模、变量较少、偏探索性分析	临床研究、变量多、需控制统计显著性偏倚
优点总结	简单、快速、效果直观	严谨无偏倚
缺点总结	容易过拟合，变量选择偏倚	计算较慢，模型稍复杂



4.1 决策树的R语言实现

数据准备

代码	解析
<pre>url <- "https://archive.ics.uci.edu/ml/machine-learning-databases/breast-cancer-wisconsin/wdbc.data"</pre>	定义数据集所在的网站，导入数据
<pre>wdbc <- read.csv(url, header = FALSE)</pre>	将该数据库导出为表格形式
<pre>colnames(wdbc) <- c("ID", "Diagnosis", paste0(rep(c("radius", "texture", "perimeter", "area", "smoothness", "compactness", "concavity", "concave_points", "symmetry", "fractal_dimension"), each = 3), "_", rep(c("mean", "se", "worst"), times = 10)))</pre>	为数据集添加列名，方便后续引用
<pre>df <- wdbc[, -1]</pre>	删除 ID 列，因为它只是编号，对分析无意义
<pre>df\$Diagnosis <- factor(df\$Diagnosis, levels = c("B", "M"), labels = c("benign", "malignant"))</pre>	将“Diagnosis”变量转为因子类型 添加标签：原始数据里 Diagnosis = “B” 表示良性（benign）， “M” 表示恶性（malignant）
<pre>df <- na.omit(df)</pre>	删除所有含有缺失值的行
<pre>set.seed(1234)</pre>	设置随机数种子，保证每次运行结果一致（可复现）
<pre>index <- sample(nrow(df), 0.7*nrow(df))</pre>	从数据集中随机抽取 70% 的行作为训练集
<pre>train <- df[index,]</pre>	根据抽取的索引划分训练集
<pre>test <- df[-index,]</pre>	剩下的 30% 作为测试集
<pre>table(train\$Diagnosis)</pre>	查看训练集中良性/恶性肿瘤的分布
<pre>table(test\$Diagnosis)</pre>	查看测试集中良性/恶性肿瘤的分布




4.1 决策树的R语言实现

经典决策树的生成

代码	解析
<pre>install.packages("rpart") install.packages("rattle")</pre>	rpart 包：核心的决策树算法 rattle 包：里面有 fancyRpartPlot，用于画决策树图
<pre>library(rpart) library(rpart.plot) library(rattle)</pre>	加载rpart包 加载rpart.plot包 加载rattle包
<pre>dtree<- rpart(Diagnosis ~ ., data = train, method = "class", parms = list(split="gini"), control = rpart.control(cp = 0, minsplit = 2, maxdepth = 30)) rpart.plot(dtree, main="Fully Grown Tree")</pre>	Diagnosis~. 表示用除了 Diagnosis 以外的所有变量来预测 Diagnosis, data=train 表示用训练集建模，method="class" 表示是分类树，parms = list(split="gini") 指定分裂标准为基尼指数。split也可指定为“信息增益”。 复杂度参数cp：设置为0，取消基于复杂度的预剪枝限制，允许树充分生长 最小分裂样本数：节点至少包含2个样本才允许分裂 树的最大深度：允许树生长到30层

4.1 决策树的R语言实现

经典决策树的生成
(未进行剪枝前)



4.1 决策树的R语言实现

应用预剪枝

代码	解析
<pre>dtree_pre <- rpart(Diagnosis ~ ., data = train, method = "class", parms = list(split="gini"), control = rpart.control(cp = 0.01, minsplit = 20, maxdepth = 5))</pre>	Diagnosis~. 表示用除了 Diagnosis 以外的所有变量来预测 Diagnosis, data=train 表示用训练集建模, method="class" 表示是分类树, parms = list(split="gini") 指定分裂标准为基尼指数。 复杂度参数cp: 设置为0.01, 限制树充分生长 最小分裂样本数: 节点至少包含20个样本才允许分裂 树的最大深度: 允许树生长到5层
<pre>fancyRpartPlot(dtree_pre, main="Fully Grown Tree (pre)")</pre>	绘制预剪枝后的决策树
<pre>dtree.pred1 <- predict(dtree_pre, test, type = "class")</pre>	对训练好的模型dtree_pre, 在测试集test上进行预测
<pre>dtree.perf1 <- table(test\$Diagnosis,dtree.pred1, dnn=c("Actual","Predicted"))</pre>	测试集的实际类别（真实标签）、模型的预测类别（预测标签） 为矩阵的行和列命名: 行=实际值, 列=预测值
<pre>dtree.perf1</pre>	输出预剪枝的混淆矩阵


4.1 决策树的R语言实现

应用预剪枝

	Predict benign	Predict malignant
Actual benign	105	8
Actual malignant	5	53

concave_points_worst: 肿瘤细胞最差凹点

fractal_dimension_mean: 肿瘤分形维度均值



4.1 决策树的R语言实现

应用后剪枝

代码	解析
<pre>best_cp <- dtree\$scptable[which.min(dtree\$scptable[, "xerror"]), "CP"]</pre>	dtree\$scptable: 是未剪枝决策树 (dtree) 的复杂度参数表, 包含不同CP值对应的树结构 (如分裂次数nsplit)、交叉验证误差 (xerror)、误差标准差 (xstd) 等信息。 which.min(dtree\$scptable[, "xerror"]): 找到cptable中交叉验证误差 (xerror) 最小的行索引。交叉验证误差越小, 说明该CP对应的树在泛化能力上表现越好。
<pre>dtree\$scptable</pre>	输出cptable表格
<pre>dtree_pruned <- prune(dtree, cp = best_cp)</pre>	根据最优cp进行后剪枝
<pre>fancyRpartPlot(dtree_pruned, sub = "Classification Tree")</pre>	可视化后剪枝的树
<pre>dtree.pred2 <- predict(dtree_pruned, test, type = "class")</pre>	对训练好的后剪枝模型dtree_pruned, 在测试集test上进行预测
<pre>dtree.perf2 <- table(test\$Diagnosis,dtree.pred2, dnn=c("Actual","Predicted"))</pre>	测试集的实际类别 (真实标签)、模型的预测类别 (预测标签) 为矩阵的行和列命名: 行=实际值, 列=预测值
<pre>dtree.perf2</pre>	输出预剪枝的混淆矩阵

4.1 决策树的R语言实现

应用后剪枝


	Predict benign	Predict malignant
Actual benign	109	4
Actual malignant	6	52

concave_points_worst: 肿瘤细胞最差凹点

concave_points_mean: 肿瘤细胞凹点均值

fractal_dimension_mean: 肿瘤分形维度均值

radius_se: 肿瘤半径标准误



4.1 决策树的R语言实现

经典决策树的ROC曲线——以后剪枝为例

代码

```
library(pROC)
```

```
dtree.prob <- predict(dtree_pruned, test, type = "prob")[, "malignant"]
```

```
y_true <- ifelse(test$Diagnosis == "malignant", 1, 0)
```


```
roc_obj <- roc(y_true, dtree.prob)
```

```
auc_val <- as.numeric(auc(roc_obj))
```

```
plot(roc_obj,  
     col = "blue",  
     lwd = 2,  
     main = "ROC Curve for Decision Tree",  
     legacy.axes = TRUE)
```

```
abline(a = 0, b = 1, lty = 2, col = "gray")
```

```
legend("bottomright",  
      legend = paste0("AUC = ", formatC(auc_val, digits = 3, format = "f"  
    bty = "n",  
    text.font = 2)
```



下角

4.1 决策树的R语言实现

条件决策树生成


代码	解析
<pre>install.packages("partykit") library(partykit)</pre>	下载 partykit 包，包里有条件推断树 (ctree) 的实现程序 调用 partykit 包
<pre>fit.ctree <- ctree(Diagnosis~.,data = train)</pre>	# 拟合条件推断树模型，Diagnosis~.：用除 Diagnosis 以外的所有变量预测 Diagnosis。data = train：在训练集上建模
<pre>plot(fit.ctree,main = "Conditional Inference Tree", gp=gpar(fontsize=8))</pre>	绘制决策树，gp = gpar(fontsize=8) 调整字体大小
<pre>ctree.pred <- predict(fit.ctree, test, type= "response")</pre>	在测试集上进行预测，type="response" 表示输出预测类别，而不是概率
<pre>ctree.pref <- table(test\$Diagnosis, ctree.pred, dnn = c("Actual","Predict"))</pre>	生成混淆矩阵，比较真实类别 vs 预测类别 dnn 设置行列名：实际类别 (Actual) 和预测类别 (Predict)
<pre>ctree.pref</pre>	打印结果

4.1 决策树的R语言实现

条件决策树的生成

	Predict Benign	Predict malignant
Actual Benign	106	7
Actual malignant	2	56

以分形维度均值为首要特征($p < 0.001$), 具有显著统计学意义), 按是否 ≤ 0.141 分裂为左右分支; 左分支再以最差凹度等特征进一步分裂, 右分支以最差凹度等特征分裂; 最终各叶节点通过柱状图展示了对应分组样本中“良性”和“恶性”的比例分布



4.2 糖尿病案例

例. 糖尿病预测

01 糖尿病的分类概述

糖尿病主要分为1型和2型，其中2型糖尿病占大多数，决策树可以帮助区分和管理不同类型的糖尿病患者。

使用Pima Indians Diabetes

任务：二分类（是否患糖尿病）

特征：怀孕次数、血糖、胰岛素、BMI、年龄等

优点：数据简单，医学特征直观，二分类任务适合讲解决策树。

02 决策树在糖尿病管理中的应用

决策树模型能够根据患者的体重、血糖水平、饮食习惯等因素，为糖尿病患者提供个性化的饮食和运动建议。

03 改善治疗效果的策略

应用决策树模型，医生可以更好地监测患者的血糖控制情况，及时调整治疗方案，从而提高糖尿病的治疗效果。

4.2 糖尿病案例

例. 糖尿病预测

数据准备

```
> install.packages("mlbench")
```

```
> install.packages("rpart")
```

```
> install.packages("rpart.plot")
```

```
> library(mlbench)
```

```
> data(PimaIndiansDiabetes2)
```

```
> df <- na.omit(PimaIndiansDiabetes2)
```

pregnant	glucose	pressure	triceps	insulin	mass	pedigree	age	diabete
1	89	66	23	94	28.1	0.167	21	neg
0	137	40	35	168	43.1	2.288	33	pos
3	78	50	32	88	31	0.248	26	pos
2	197	70	45	543	30.5	0.158	53	pos
1	189	60	23	846	30.1	0.398	59	pos
5	166	72	19	175	25.8	0.587	51	pos
0	118	84	47	230	45.8	0.551	31	pos
1	103	30	38	83	43.3	0.183	33	neg
1	115	70	30	96	34.6	0.529	32	pos
3	126	88	41	235	39.3	0.704	27	neg
11	143	94	33	146	36.6	0.254	51	pos
10	125	70	26	115	31.1	0.205	41	pos
1	97	66	15	140	23.2	0.487	22	neg
13	145	82	19	110	22.2	0.245	57	neg
3	158	76	36	245	31.6	0.851	28	pos
3	88	58	11	54	24.8	0.267	22	neg
4	103	60	33	192	24	0.966	33	neg
4	111	72	47	207	37.1	1.39	56	pos
3	180	64	25	70	34	0.271	26	neg
9	171	110	24	240	45.4	0.721	54	pos
1	103	80	11	82	19.4	0.491	22	neg
1	101	50	15	36	24.2	0.526	26	neg
5	88	66	21	23	24.4	0.342	30	neg
8	176	90	34	300	33.7	0.467	58	pos
7	150	66	42	342	34.7	0.718	42	neg
7	187	68	39	304	37.7	0.254	41	pos
0	100	88	60	110	46.8	0.962	31	neg
0	105	64	41	142	41.5	0.173	22	neg
2	141	58	34	128	25.4	0.699	24	neg
1	95	66	13	38	19.6	0.334	25	neg
4	146	85	27	100	28.9	0.189	27	neg
2	100	66	20	90	32.9	0.867	28	pos
5	139	64	35	140	28.6	0.411	26	neg
4	129	86	20	270	35.1	0.231	23	neg
7	83	78	26	71	29.3	0.767	36	neg
2	110	74	29	125	32.4	0.698	27	neg
2	100	68	25	71	38.5	0.324	26	neg
15	136	70	32	110	37.1	0.153	43	pos
4	123	80	15	176	32	0.443	34	neg
7	81	78	40	48	46.7	0.261	42	neg
2	142	82	18	64	24.7	0.761	21	neg
6	144	72	27	228	33.9	0.255	40	neg
1	71	48	18	76	20.4	0.323	22	neg
6	93	50	30	64	28.7	0.356	23	neg
1	122	90	51	220	49.7	0.325	31	pos
1	81	72	18	40	26.6	0.283	24	neg
1	126	56	29	152	28.7	0.801	21	neg
4	144	58	28	140	29.5	0.287	37	neg
3	83	58	31	18	34.3	0.336	25	neg
0	95	85	25	36	37.4	0.247	24	pos


4.2 糖尿病案例

例. 糖尿病预测

```
# 构建决策树
> set.seed(123)
> n <- nrow(df)
> train_index <- sample(1:n, size = 0.7*n)
> train <- df[train_index, ]
> test <- df[-train_index, ]

## 用训练集建模
> fit <- rpart(diabetes ~ ., data = train, method = "class")
> rpart.plot(fit,
  type = 3, extra = 104, under = TRUE, faclen = 0,
  cex = 0.8, tweak = 1.2, fallen.leaves = TRUE,
  main = "Decision Tree for Diabetes Prediction")
```

通过血糖、家族史、年龄、体重等多个与糖尿病相关的特征，决策树逐层细化样本分组，



4.2 糖尿病案例


例. 糖尿病预测

```
> pred <- predict(fit, test, type = "class")
> table(Predicted = pred, Actual = test$diabetes)

## 预测概率
> pred_prob_train <- predict(fit, train, type = "prob")[,2] # 训练集概率
> pred_prob_test  <- predict(fit, test, type = "prob")[,2] # 测试集概率

## 计算 ROC
> roc_train <- roc(train$diabetes, pred_prob_train, levels =
c("neg","pos"))
> roc_test  <- roc(test$diabetes, pred_prob_test, levels = c("neg","pos"))

## 绘图
> plot(roc_train, col="blue", lwd=2, main="ROC Curve: Train vs Test")
> plot(roc_test, col="red", lwd=2, add=TRUE)
> legend("bottomright", legend=c(paste0("Train AUC=",
round(auc(roc_train),3)), paste0("Test AUC=",
round(auc(roc_test),3))), col=c("blue","red"), lwd=2)
```



小结

决策树核心思想回顾

- 目标：通过不断提出“最佳问题”将数据划分成不同类别或预测值。
- 分裂依据：特征的取值，例如“mean radius > 15”。
- 叶子节点：最终分类结果（良性/恶性）或回归预测值（生存时间等）。
- 核心点：每次选择分裂特征的目标是 最大化节点纯度。



三大算法对比

算法	分裂标准	特点	优缺点
ID3	信息增益	简单，易理解	无剪枝 → 易过拟合
C4.5	信息增益率	处理连续特征，支持剪枝	复杂度高，剪枝策略多样（预剪枝、后剪枝、悲观剪枝）
CART	基尼指数 / MSE	分类和回归统一框架	支持代价复杂度剪枝，解释性强，但对噪声敏感



小结

剪枝策略回顾

- 预剪枝：在建树过程中停止无意义分裂，简单快速，但可能欠拟合
- 后剪枝：先长成大树，再通过验证集修剪子树，泛化能力强
- 悲观剪枝（C4.5特色）：不依赖验证集，用训练误差修正实现后剪枝
- CART 剪枝：使用代价复杂度剪枝（CCP），分类与回归统一处理

 小结**划分标准的差异：**

- ID3 使用信息增益偏向特征值多的特征,
- C4.5 使用信息增益率克服信息增益的缺点, 偏向于特征值小的特征,
- CART 使用基尼指数克服 C4.5 需要求 $\log$ 的巨大计算量, 偏向于特征值较多的特征。

使用场景的差异：

- ID3 和 C4.5 都只能用于分类问题
- CART 可以用于分类和回归问题
- ID3 和 C4.5 是多叉树, 速度较慢
- CART 是二叉树, 计算速度很快

小结**样本数据的差异：**

- ID3 只能处理离散数据且缺失值敏感，C4.5 和 CART 可以处理连续性数据且有多种方式处理缺失值
- 从样本量考虑的话，小样本建议 C4.5、大样本建议 CART
- C4.5 处理过程中需对数据集进行多次扫描排序，处理**成本耗时较高**，而 CART 本身是一种大样本的统计方法，**小样本处理下泛化误差较大**

样本特征的差异：

- ID3 和 C4.5 层级之间只使用一次特征
- CART 可多次重复使用特征

 小结

剪枝策略的差异：

- ID3 没有剪枝策略
- C4.5 是通过悲观剪枝策略来修正树的准确性
- CART 是通过代价复杂度剪枝



中山大學
SUN YAT-SEN UNIVERSITY

谢 谢 大 家

